

CAUSAL INFERENCE · EDUCATION ECONOMICS · AGENT ERA

《教育经济学应用：Agent 时代下的因果推断方法》

徐万蓉（北京大学教育学院）

2026年4月

面向 Agent 时代的因果推断方法手册：教育经济学应用

面向教育经济学、劳动经济学与公共政策实证研究者。

核心立场：Agent 可以自动化检索、编码、脚本草拟、诊断清单与写作校对；识别假设、数据合规、结果核验与结论责任始终属于研究者。

阅读说明

本版按“理论基础 → 识别假设 → 模型设定 → Stata/R/Python 实现 → 教育经济学案例 → Agent 验证点”重排原手册的 31 个主题。代码均为核心框架，变量名、固定效应、聚类层级与样本限制必须根据具体研究设计调整。引用事实、政策条款、软件接口和数值结果应回到原始文献、官方文档与本地运行日志核验。

第一编 理论基础与研究设计

第 1 章 从相关到因果：潜在结果、估计对象与教育生产函数

教育经济学的因果问题不是“成绩与投入是否相关”，而是：对给定对象，若其接受与未接受某教育处理，结果会相差多少。令 $D_i \in \{0, 1\}$ 表示处理， $Y_i(1)$ 与 $Y_i(0)$ 表示潜在结果，则个体效应为 $\tau_i = Y_i(1) - Y_i(0)$ 。由于同一人不能同时被观察到两种状态，研究设计的任务是构造可信反事实。

常见估计对象包括平均处理效应 $ATE = E[Y(1) - Y(0)]$ 、处理组平均效应 $ATT = E[Y(1) - Y(0) | D = 1]$ ，以及工具变量下顺从者的局部平均效应 LATE。写作时必须说清估计对象属于哪一种，不能把局部资格线效应、试点效应或顺从者效应泛化为“所有学生的政策效果”。

教育生产函数提醒我们：家庭资源、学生能力、学校质量、教师行为、同伴与地区环境可能同时影响处理和结果。研究起点应是一张因果图，明确处理前混淆 X 、中介 M 、选择变量 S 与潜在溢出网络，而不是先搜一个回归命令。

教育案例：评估课后服务扩容时，家庭教育投入、学校供给能力和既有成绩可能同时影响服务使用与成绩；政策后补习支出则可能是中介而非应控制的“背景变量”。

Agent 验证点：要求模型逐项标出变量的发生时间和因果角色；对任何它无法基于制度材料判断的箭头，输出“待人工确认”，而不是自动归入控制变量。

第 2 章 随机与准随机：设计优先于估计

随机试验的识别来自处理分配与潜在结果独立： $(Y_i(0), Y_i(1)) \perp D_i$ 。教育实验常在学生、班级、教师或学校层面随机；估计、标准误和依从性报告必须匹配随机化层级。若按学校随机却把学生当独立样本，精度会被虚假放大。

准实验不因名称而成立。资格规则、行政轮转、建设时点、改革批次或地理边界只能提供候选外生变化；研究者需要证明处理分配机制、排除竞争性路径，并报告对最脆弱假设的诊断。

* 集群随机试验：示意

```
reg score_z assigned baseline_score i.grade, vce(cluster school_id)
```

* ITT 是分配效应；TOT 需要另行说明依从性与工具变量条件

第 3 章 可观测选择：匹配、加权与双重稳健

若在处理前协变量 X 条件下可忽略性成立， $\{Y(0), Y(1)\} \perp D \mid X$ ，且满足重叠性 $0 < P(D = 1 \mid X) < 1$ ，则匹配、逆概率加权和双重稳健估计可用于调整可观测选择。它们不能解决未观测的家庭偏好、学生动机或学校筛选。

教育研究须先定义协变量窗口：既往成绩、家长教育、家庭资源、地区、学校特征和既有教育选择可以是处理前变量；当前出勤、政策后补习、现任教师评价可能已在处理路径上。加权后报告平衡、权重分布、有效样本量与共同支撑，而不只报告显著性。

第二编 核心识别策略与可运行框架

第 4 章 双重差分与交错 DID

两组两期 DID 为：

$$\hat{\tau}_{DID} = \left(\bar{Y}_{T,post} - \bar{Y}_{T,pre} \right) - \left(\bar{Y}_{C,post} - \bar{Y}_{C,pre} \right).$$

核心假设是没有处理时处理组与对照组具有平行趋势，且不存在改变处理前行为的预期。分批实施时，裸双向固定效应可能将已处理组作为后处理组的对照；当效应随队列或暴露时长变化时，Goodman-Bacon 分解所揭示的坏比较会污染 TWFE 系数。主结果应使用按队列—时期构造的 ATT，并交叉验证 Callaway & Sant'Anna、Sun & Abraham 或 Borusyak 等的稳健框架。

* Stata：交错处理的队列-时期 ATT

```
csdid outcome, ivar(unit_id) time(year) gvar(first_treat_year) method(dripw) notyet
```

```
estat event, window(-5 5)
```

```
estat simple
```

```
# R: 示意; 明确 cohort、时间、单位与对照组定义
library(did)
att <- att_gt(yname="outcome", tname="year", idname="unit_id",
             gname="first_treat_year", data=df, control_group="notyettreated")
aggte(att, type="dynamic")
```

```
# Python: 先构造可审计的 cohort 与事件时间, 再调用经核验的软件接口
df["event_time"] = df["year"] - df["first_treat_year"]
cohort_counts = df.groupby(["first_treat_year", "year"]).size()
```

教育案例：分批课后服务、教师交流轮岗、学前教育普惠试点或教育数字化项目。除事件研究外，必须核对实际落地日期、财政与招生政策同步性、学生跨区流动、学校合并和测验口径变化。

Agent 验证点：提示词应强制模型回答“是否交错处理、已处理单位是否会成为对照、聚类是否与政策赋值层级一致”。如果任一项不清楚，停止生成主回归结论。

第 5 章 工具变量：相关性、排他性与 LATE

设工具为 Z_i ，处理为 D_i ：

$$D_i = \pi_0 + \pi_1 Z_i + X_i' \pi_2 + u_i, \quad Y_i = \beta_0 + \tau \hat{D}_i + X_i' \beta_2 + \varepsilon_i.$$

第一阶段相关性可检验，排他性不能由 F 统计量证明。单调性成立时，2SLS 估计的是由 Z 改变处理状态的顺从者的 LATE。教育回报研究必须说明工具推动的是谁的教育选择，以及工具是否可能通过迁移、当地劳动力市场、同伴网络或家庭决策直接影响工资。

```
ivreghdfe log_wage experience c.experience#c.experience ///
          (years_schooling = z), absorb(cohort region) cluster(region)
```

```
from linearmodels.iv import IV2SLS
fit = IV2SLS.from_formula("log_wage ~ 1 + experience + [years_schooling ~ z]", data=df).fit(
    cov_type="clustered", clusters=df["region"]
)
print(fit.summary)
```

最低报告包括第一阶段、弱工具稳健推断、排他性制度论证、LATE 人群和外部效度边界。不要把“临近大学”“出生季度”“资格规则”等标签本身当作排他性证明。

第 6 章 断点回归：阈值附近的局部随机

令运行变量为 X 、阈值为 c ，锐利 RD 的效应为：

$$\tau_{RD} = \lim_{x \downarrow c} E[Y \mid X = x] - \lim_{x \uparrow c} E[Y \mid X = x].$$

教育中的典型场景是录取线、奖助学金资格线、贫困认定线、入园年龄线和学校评级阈值。报告局部多项式、带宽、偏误校正区间、密度检验、协变量连续性和安慰剂断点；阈值附近的效应不能自动推广到全部学生。

```
rdrobust outcome running, c(0) p(1) kernel(triangular)
rdplot outcome running, c(0)
rddensity running, c(0)
```

```
library(rdrobust)
rdrobust(y=df$outcome, x=df$running, c=0)
```

教育案例：奖学金资格线附近，家庭和学校可能通过材料申报、成绩复议或择校策略操纵运行变量。密度连续并非唯一检验；还须查验成绩生成和资格认定流程。

第 7 章 合成控制、合成 DID 与面板反事实

当少数地区实施重大高校布局、教育财政或学制改革，且有足够长的处理前序列时，构造加权捐赠池以逼近处理单位的处理前结果路径。关键假设是捐赠池可提供可信反事实，并非“拟合越好就越因果”。报告处理前拟合、置换检验、留一法、捐赠池组成与同期改革排除规则。

```
* 示意：处理地区 1，处理开始于 2018
synth outcome predictors, trunit(1) trperiod(2018) keep("output/scm_results.dta") replace
```

空间教育研究还应说明地理边界、校区/地区 crosswalk、邻近地区溢出与捐赠池是否受到相同的高等教育扩张冲击。

第 8 章 双重机器学习（DML）

部分线性模型写为：

$$Y = \theta D + g(X) + \varepsilon, \quad D = m(X) + v.$$

以机器学习估计 $g(X)$ 与 $m(X)$ ，通过 Neyman 正交化和交叉拟合减小正则化与过拟合偏差。DML 处理的是高维、非线性的可观测混淆，不解决不可观测选择。

```
from doubleml import DoubleMLData, DoubleMLPLR
from sklearn.ensemble import RandomForestRegressor

dml_data = DoubleMLData(df, y_col="outcome", d_cols="treat", x_cols=x_columns)
ml_l = RandomForestRegressor(random_state=2026)
ml_m = RandomForestRegressor(random_state=2026)
dml = DoubleMLPLR(dml_data, ml_l, ml_m, n_folds=5)
dml.fit()
print(dml.summary)
```

教育应用中， X 可包括处理前成绩、家庭背景、学校资源和地区供给；不得将处理后出勤、补习或当前成绩混入 X 。报告折数、学习器、随机种子、重叠诊断及与透明基准模型的比较。

第 9 章 异质性处理效应与政策学习

条件平均处理效应为 $CATE(x) = E[Y(1) - Y(0) | X = x]$ 。因果森林、广义随机森林与 meta-learners 可帮助探索异质性，但异质性结果尤其容易受多重比较和数据挖掘影响。预先定义教育公平相关维度：家庭经济地位、城乡、性别、基线能力、学校资源、学段和流动儿童身份；报告每组样本量、置信区间与校准检验。

政策学习只在明确的福利目标、约束条件、公平规则和可执行资源边界下才有意义。模型给出的“最优投放”不能替代教育资源配置中的伦理与制度判断。

第 10 章 面板与其他准实验设计

面板固定效应、事件研究、三重差分、边界设计、鼓励设计和移位份额工具都依赖不同的反事实逻辑。选择方法前先问：处理在哪一层级分配，变化来自时间、空间、资格、规则还是外生冲击；对照单位为何可比；处理是否可能溢出；结果是否跨期可比。方法名称不是识别论证。

第 11 章 敏感性分析：量化不可检验假设

敏感性分析不能把不可信设计变可信，但能说明结论对未观测混淆、趋势偏离、样本选择或函数形式的脆弱程度。DID 可使用对平行趋势偏离的敏感性分析；可观测选择研究可报告 Oster 型界限或 Rosenbaum 界限；IV 应报告弱工具稳健区间。写作时用“在给定偏离幅度下结论是否改变”，而不是“敏感性分析证明因果”。

第 12 章 文本、非结构化数据与因果

政策文件、学校报告、教师教案、课程评价和家长开放式回答可形成文本变量，但文本标签可能同时受学校质量、地区资源和政策执行影响。固定提示词、模型版本、人工标注金标准、抽样复核和错误类型；含学生、教师或学校可识别信息的文本不得上传至未经授权的外部模型。

第 13 章 机制与中介

机制分析首先是理论和制度工作。处理影响某个中间变量，只能提供支持性证据；在主回归中加入处理后中介往往改变估计对象或引入偏误。更稳妥的做法是在与主结果相同的识别框架下分别估计政策对候选机制变量的简约式影响，并明确哪些路径仍不可识别。

第 14 章 溢出、干扰与空间网络因果

学生受同伴、教师跨班、家长信息网络、跨校流动与邻近地区政策影响，常违反“一个单位的结果只由自己处理决定”的假设。研究者须说明网络或地理边界，区分直接、间接与总体效应，并使聚类、随机化和处理定义与干扰结构相匹配。控制同伴均值的回归系数不自动等于同伴因果效应。

第 15 章 实验设计：田野 RCT 与线上 A/B

实验开始前锁定随机化单位、分层规则、主要结果、分析窗口、依从性、失访、样本量与停止规则。教育场景中还需获得学校、教师、家长与学生所需的授权，避免干预加重既有不平等。报告 ITT、依从性和潜在溢出；不要把执行偏差藏在附录。

第 16 章 多重检验、预注册与推断可信度

教育项目常有多项成绩、行为、心理和家庭结果。预先区分主要与次要结果、确认性与探索性分析，并按结果族处理多重检验。预注册不是禁止探索，而是使读者能识别哪些结论经受了确认性检验。Agent 的低成本批量跑规格会放大选择性报告风险，项目日志必须保留。

第 17 章 部分识别：无法点识别时的诚实结论

当选择机制、缺失机制或外部效度无法被完整识别时，使用合理边界、单调性或排序假设给出区间，通常比用脆弱假设硬给一个点估计更可信。部分识别的价值在于透明展示“数据和假设共同允许我们知道多少”。

第三编 Agent 协作、复现与验证

第 18 章 面向 Agent 设计的因果工具库

因果库应保存经过验证的任务卡，而不是零散提示词：识别诊断卡、数据体检卡、交错 DID 卡、RD 卡、IV 卡、表图卡和复现卡。每张卡包含输入、输出格式、禁止事项、人工核验点和失败时的停线条件。

第 19 章 研究者的新角色

研究者从“手工调用每个软件命令”转向研究设计者、数据守门人、结果审稿人和责任承担者。高价值工作包括判断制度是否提供可信反事实、决定哪些变量不能控制、解释估计对象、识别不合理结果，并拒绝用 AI 掩盖不确定性。

第 20 章 给 Agent 下因果指令

一条合格指令须给出研究问题、观察单位、处理分配、结果测量时点、目标估计量、协变量的时间角色、固定效应、聚类层级、必须报告的诊断和禁止的结论。示例：

估计区县分批课后服务扩容对初中生成绩的 ATT。处理在区县-年份层分配，结果在学生-年份层观察。
先列出识别假设与需要核验的政策事实；若为交错处理，禁止以裸 TWFE 作为主结论。
标准误至少聚类到区县；不得控制政策后补习支出或出勤。输出代码草案、样本流、事件研究、安慰剂和敏感性清单；对没有输入支持的事实写“待核验”。

第 21 章 Agent 最常犯的因果错误

高频错误包括：把相关写成因因果；遗漏估计对象；把处理后变量当控制；混淆个体与政策层级；忽略交错 DID；用第一阶段显著替代 IV 排他性；把 RD 阈值两侧差异当全样本效应；把机制回归当机制识别；把不显著预趋势当平行趋势证明；编造文献、政策或软件语法。每次输出均应按此清单自查。

第 22 章 可复现与可信

原始数据只读、清洗脚本、分析脚本、表图脚本、环境文件、随机种子、决策日志和 README 必须从第一天开始积累。受限教育数据无法公开时，公开变量字典、样本流、代码框架、权限说明与可在模拟数据运行的示例；可复现不等于泄露数据。

第 23 章 LLM 做因果推断的能力边界

LLM 可以解释常见公式、阅读代码、发现明显不一致和生成候选诊断；它不能从提示词中获得未提供的制度事实，也不能验证外生性、运行真实数据或对论文结论负责。模型自信的语气不是证据强度。

第 24 章 个人因果分析工作台

推荐目录为 data_raw/、data_clean/、code/、output/、docs/、logs/ 与 environment/。每个项目只保留一个主运行入口；所有图表由脚本生成；密钥、受限数据、个人路径和临时文件不进入版本库。跨设备时以相对路径与环境检查脚本为准。

第 25 章 把大模型当被试、标注员或合成数据

模型输出可以用于生成问卷草案、测试文本标注规则、形成反事实叙述或研究模型偏差；它不是对真实学生、家长、教师或学校的随机抽样。若使用 LLM 标注文本，应报告模型、提示词、抽样人工复核和与金标准的一致性；若使用 LLM 模拟主体，不得把其输出直接解释为真实政策效应。

第 26 章 AI 辅助复现与审稿

复现时，Agent 可帮助定位依赖、阅读日志、比较表图和生成审计清单；研究者必须亲自运行脚本、检查数据版本、核对样本流和解释差异。审稿辅助应按“识别、数据、推断、外部效度、写作”分类意见，避免让模型代替作者决定是否接受一个因果解释。

第四编 教育经济学实战案例

第 27 章 教育回报：OLS、IV 与 DML 并排

以教育年限对对数工资的影响为例，OLS 描述在可观察控制下的条件相关；IV 在排他性、相关性与单调性条件下识别顺从者的 LATE；DML 在高维可观察混淆下更灵活地估计条件相关结构。三者回答不同问题，数值不同并不意味着谁“错了”。

写作时并列列出：样本与劳动参与选择、结果观察窗口、控制变量时间顺序、第一阶段与排他性论证、DML 学习器与重叠性，以及不同估计对象的外推边界。对职业教育、专业选择、大学质量或继续教育，工具变量和样本选择须重新论证，不能照搬教育年限研究。

第 28 章 交错 DID：教育政策分批落地

设区县在不同年份扩容课后服务，结果为学生学习投入或标准化成绩。第一步不是回归，而是建立“发布—试点—实际覆盖—结果观察”的时间线；第二步描述入选机制与同期财政、招生、督导变化；第三步构造首次处理年份与事件时间；第四步以稳健队列—时期 ATT 估计主结果；第五步进行动态、安慰剂、样本流失、替代对照组、早处理组剔除和敏感性检验。

结论应表述为在给定研究时期与样本中，政策扩容对受影响学生的估计效应；若结果只覆盖短期测试或行为，不可直接断言长期人力资本、家庭福利或全国推广效果。

第 29 章 中国教育政策试点评估

试点城市、区县或学校通常不是随机抽取的。完整评估需收集正式文件、申报条件、评审标准、名单、地方配套与实际执行证据；估计前用处理前特征解释选择过程。若选择主要依赖可观测特征，可在透明的条件平行趋势框架下估计；若高度依赖处理前结果路径，应考虑合成控制类设计；若无法建立可信反事实，应收缩为描述性或机制性研究，而不是强行声称因果。

第 30 章 一次完整的人机协作实录

研究者：课后服务按区县分批扩容，想估计对校外补习和成绩的影响。**Agent 的合格第一回应：**先要求处理名单、实际落地日期、样本单位、学生跨区域规则、测验可比性、同期政策和政策赋值层级；指出交错处理下不能直接用裸 TWFE。**研究者的下一步：**核验文件，建立队列变量与样本流，运行稳健 DID 和事件研

究。**Agent 的第二回应**：基于实际日志检查 cohort 样本、处理前系数、聚类、安慰剂和替代对照；对无法检验的趋势偏离提出敏感性分析。**最终责任**：研究者决定识别是否可信、哪些结果进入正文以及如何陈述政策含义。

第 31 章 结果怎么写：把估计变成可审查的段落

结果段落应依次交代估计对象、样本与时期、制度处理、量级与不确定性、识别假设及其支持性诊断、外部效度边界。模板如下：

在 [样本与时期] 中，采用 [识别设计]，我们估计 [处理] 对 [结果] 的 [ATT/ATE/LATE/局部效应] 为 [量级与单位]（[标准误或置信区间]）。该解释依赖于 [关键假设]；[动态检验、安慰剂、替代估计或敏感性分析] 提供了支持性证据。该结果适用于 [目标人群/阈值附近/顺从者]，不直接说明 [其他时期、学段或推广条件] 下的效果。

禁止将不显著写成“没有影响”，将显著写成“政策重要”，将局部效应写成普遍结论，或把机制支持性证据写成完整传导证明。

附录 A 识别策略速查表

方法	识别来源	核心假设	必报诊断	教育研究中的警报
RCT	随机分配	随机化、有限干扰	平衡、依从、流失	班级/学校聚类与溢出
DID	相对变化	平行趋势、无预期	动态、安慰剂、聚类	分批政策、同步财政与学生流动
IV	外生工具	相关、排他、单调	第一阶段、弱工具稳健推断	LATE 人群与直接路径
RD	阈值规则	阈值附近连续/局部随机	密度、协变量、带宽	成绩/资格操纵与局部外推
SCM	加权反事实	捐赠池与处理前拟合	置换、留一、拟合比	少数处理地区与同期改革
DML	高维可观测混淆	可忽略性、重叠	交叉拟合、重叠、学习器稳健性	处理后变量与不可观测选择

附录 B 可打印的 Agent 核查卡

- 研究问题、单位、处理、结果、估计对象是否写全？
- 处理如何分配；比较组为什么可信？
- 哪些变量发生在处理后，是否被错误控制？
- 政策时点、空间边界、样本流和结果口径是否已核验？

- 5. 固定效应、权重和聚类层级是否与设计一致?
- 6. 已完成哪些设计诊断、安慰剂和敏感性分析?
- 7. 任何文献、数字、政策细节是否可回到原始来源?
- 8. 任何 AI 生成代码是否已在真实数据上运行并审查逻辑?
- 9. 结论是否超过估计对象、样本和识别边界?
- 10. 代码、日志、表图与 README 是否可重建结果?

附录 C AI 使用披露示例

本研究在文献组织、代码注释、格式检查与语言校对环节使用生成式 AI 辅助。研究问题、识别设计、数据处理、统计分析、结果核验与全文定稿均由作者完成。文中事实、引文、政策信息和实证结果均根据原始资料或可复现代码核验；受限微观数据未输入未经授权的外部服务。

附录 D 关键方法的实现与诊断补充

下表补足第 3、7、9-17 章的最小实现规范。代码仅为骨架；每项方法在进入论文前都必须配合本章对应的识别论证与诊断，而非只运行一次命令。

方法	Stata/R/Python 起点	必须同时保存的诊断
匹配/加权	<code>teffects ipw</code> 、 <code>R WeightIt</code>	倾向得分重叠、协变量平衡、极端权重、有效样本
合成控制	<code>synth</code> 、 <code>R Synth</code>	处理前拟合、置换、留一、捐赠池与同期冲击
因果森林	<code>R grf</code> 、 <code>Python econml</code>	诚实样本分割、校准、分组样本量、多重比较
DDD	<code>reghdfe y i.treat##i.post##i.group</code>	第三维比较的平行趋势、固定效应和聚类层级
机制	主设计下分别估计中间结果	中介的时序、主设计一致性、不可识别路径
文本编码	固定模型和提示词批量标注	人工金标准、一致性、版本、敏感信息边界
RCT	<code>reg y assigned, vce(cluster clusterid)</code>	随机化平衡、失访、依从、溢出、主要结果族
多重检验	<code>R p.adjust</code> / 预设结果族	主要/次要结果、校正方法、探索性标记

```
* 交错 DID 的数据约定：从未处理为 0；处理组为首次实际处理年份。  
* 先核验，而不是直接把缺失或零随意混用。  
tab first_treat_year, missing  
assert first_treat_year == 0 | inrange(first_treat_year, 2000, 2035)  
tab first_treat_year year  
by first_treat_year year: egen cohort_year_n = count(outcome)  
gen byte treated = year >= first_treat_year if first_treat_year > 0  
replace treated = 0 if first_treat_year == 0  
tab first_treat_year treated, missing  
  
* DDD：示意；第三维 group 必须有独立的理论比较含义。  
reghdfe outcome i.treat##i.post##i.group controls, absorb(unit_id year) vce(cluster policy_unit)
```

```
# 简化的文本编码人工复核框架  
sample = df.sample(n=min(200, len(df)), random_state=2026).copy()  
# 人工对 sample["human_label"] 标注；模型标签写入 sample["llm_label"]。  
agreement = (sample["human_label"] == sample["llm_label"]).mean()  
print({"audit_n": len(sample), "exact_agreement": agreement})  
# 将模型名称、提示词哈希、运行日期和错误类型写入审计表。
```

方法停线规则：若从未处理组编码不明、cohort 分布没有输出、处理后控制变量混入主规格、结果测量跨期不可比、或诊断与识别假设不匹配，则不得进入机制、异质性或论文写作阶段。

附录 E 参考文献（方法学核心）

- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Borusyak, K., Jaravel, X., & Spiess, J. (2024). Revisiting Event Study Designs: Robust and Efficient Estimation. *Review of Economic Studies*, 91(6), 3253-3285.
- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-Differences with Multiple Time Periods. *Journal of Econometrics*, 225(2), 200-230.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *The Econometrics Journal*, 21(1), C1-C68.
- Goodman-Bacon, A. (2021). Difference-in-Differences with Variation in Treatment Timing. *Journal of Econometrics*, 225(2), 254-277.
- Imbens, G. W., & Angrist, J. D. (1994). Identification and Estimation of Local Average Treatment Effects. *Econometrica*, 62(2), 467-475.
- Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.

- Sun, L., & Abraham, S. (2021). Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects. *Journal of Econometrics*, 225(2), 175-199.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228-1242.

结语

Agent 时代并未降低因果推断的标准。它使执行更快，也使研究者更有责任把制度事实、识别假设、数据口径、代码日志和结果边界说清楚。对教育经济学而言，最好的工作流是能让一项研究从学生、家庭、学校 and 政策的真实制度世界出发，并在每一步都经得起复核。